Re-escritura de consultas

Clase 15

IIC 3413

Prof. Cristian Riveros

Re-escritura de consultas

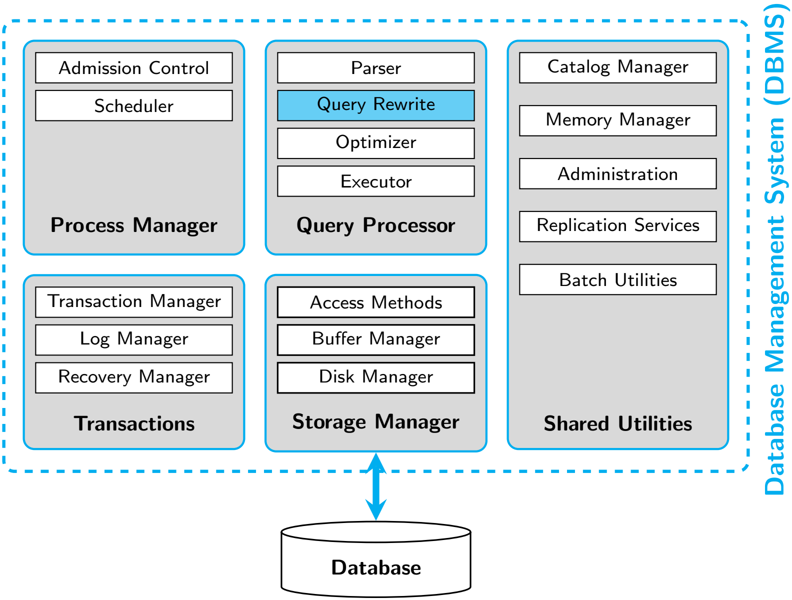

Zoom al optimizador de consultas

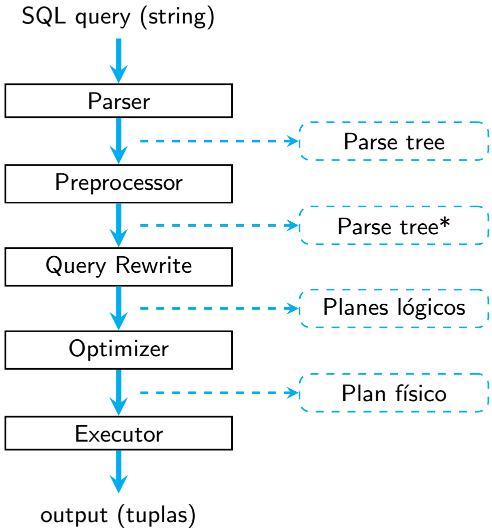

Plan lógico

Definición

Un **plan lógico** es un árbol ordenado y etiquetado $\mathcal{T}$ tal que:

- $\text{label}(h)$ es una relación,
- $\text{label}(n)$ es un operador de algebra relacional y
- $|\text{children}(n)| = \text{arity}(\text{label}(n))$

para todo nodo hoja $h \in \text{nodes}(\mathcal{T})$ y nodo interno $n \in \text{nodes}(\mathcal{T})$.

Ejemplo

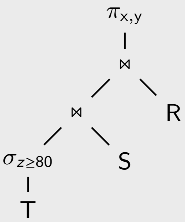

Re-escritura de consultas

1. Convertir el árbol de parsing en un **plan lógico**.
2. Reescribe consulta aplicando **reglas** de algebra relacional.
3. Crea un set de planes lógicos **prometedores** para ser optimizados.

Outline

Outline

¿cómo convertimos un árbol de parsing en un plan lógico?

```
SELECT   <SelList>
FROM     <FromList>
WHERE    <Condition>
```

1. Combinamos las relaciones en el `<FromList>` con **productos cruz**:

$$R_1 \times \ldots \times R_n$$

2. Aplicamos **selección** con la condición C dada en el `<Condition>`:

$$\sigma_{\texttt{<Condition>}}(\ R_1\ \times\ \ldots\ \times\ R_n\ )$$

3. Aplicamos **proyección** con las atributos dados en el `<SelList>`:

$$\pi_{\texttt{<SelList>}}\ (\ \sigma_{\texttt{<Condition>}}(\ R_1\ \times\ \ldots\ \times\ R_n\ )\ )$$

Ejemplo de árbol de parsing a plan lógico

```
SELECT   pName, mStadium, goals
FROM     Players AS P, Matches AS M, Players_Matches AS PM
WHERE    P.pId = PM.pId AND PM.mId = M.mId AND
         P.pYear ≥ 1985
```

$$\pi_{\text{pName,mStadium,goals}}$$

$$\sigma_{P.pId=PM.pId \,\wedge\, PM.mId=M.mId \,\wedge\, P.pYear \geq 1985}$$

$$\times$$

$$\text{P} \qquad \text{PM} \qquad \text{M}$$

Uso de vistas (no materializadas)

Por cada **vista** V en un plan lógico P:

- usamos su definición para construir un plan lógico P' para V.
- colgamos P' en cada nodo que es mencionada en P.

Uso de vistas (no materializadas)

Ejemplo

```
SELECT   name, stadium
FROM     Players P, Stadiums S
WHERE    id = pId AND
         year ≥ 1985
```

```
CREATE VIEW   Stadiums AS
SELECT        pId, stadium
FROM          Matches
```

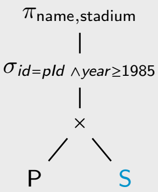

Uso de vistas (no materializadas)

Ejemplo

```
SELECT   name, stadium
FROM     Players P, Stadiums S
WHERE    id = pId AND
         year ≥ 1985
```

```
CREATE VIEW   Stadiums AS
SELECT        pId, stadium
FROM          Matches
```

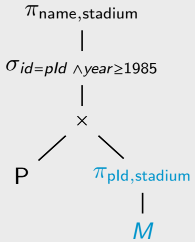

Uso de consultas anidadas

Consultas anidada: consulta que contienen una subconsulta embebida en:

- `FROM`
- `WHERE`
- `HAVING`

Uso de consultas anidadas

Ejemplos

Anidación en `FROM`:

- ```
  SELECT  DISTINCT pName, pYear
  FROM    Players, (  SELECT  mId
                      FROM    Matches
                      WHERE   mGoals ≥ 3   )
  WHERE   pId = mId
  ```
  ```

Uso de consultas anidadas

Ejemplos

Anidación en `WHERE`:

- ```
  SELECT  pName, pGoals
  FROM    Players
  WHERE   pGoals = (  SELECT  MAX(pGoals)
                      FROM    Players        )
  ```

- ```
  SELECT  DISTINCT pName
  FROM    Players
  WHERE   pYear IN (  SELECT  mYear
                      FROM    Matches
                      WHERE   type = 'World Cup'   )
  ```

Uso de consultas correlacionadas

Consulta correlacionada: consulta anidada que contienen una subconsulta embebida con una referencia a la consulta externa.

Ejemplo

```
SELECT  pName, pYear
FROM    Players AS P
WHERE   1 ≤  (  SELECT  AVG(mGoals)
                FROM    Matches AS M
                WHERE   M.mId = P.pId   )
```

¿cómo desanidamos estas consultas?

(ver pizarra)

Outline

Reglas de reescritura de consultas

Definición

Dos consultas Q_1 y Q_2 en algebra relacional son **equivalentes** ($Q_1 = Q_2$) ssi:

para toda instancia D, se tiene que: $Q_1(D) = Q_2(D)$.

Reescritura de consultas

Dado una consulta Q, buscar una consuta Q' tal que:

1. $Q = Q'$ y
2. evaluar Q' con un plan físico sea **más eficiente**.

¿cómo encontramos Q'?

Reglas de reescritura de consultas

Usando reglas muy sencillas de algebra relacional:

1. Conmutatividad.
2. Asociatividad.
3. Distributividad.
4. Distribución de selección (push-selection).
5. Distribución de proyección (push-projection).
6. Simplificación de productos.
7. Eliminación de duplicados.

Una de las **grandes ventajas** de algebra relacional!

Conmutatividad

Las siguientes consultas son **equivalentes**:

$$
\begin{aligned}
R \times S &= S \times R \\
R \bowtie S &= S \bowtie R \\
R \cap S &= S \cap R \\
R \cup S &= S \cup R
\end{aligned}
$$

Estas reglas son validas tanto para **set**- como **bag-semantics**.

- ¿es p-join conmutativo?
- ¿cuál es la importancia de estas reglas?

Asociatividad

Las siguientes consultas son **equivalentes**:

$$
\begin{aligned}
(R \times S) \times T &= R \times (S \times T) \\
(R \bowtie S) \bowtie T &= R \bowtie (S \bowtie T) \\
(R \cap S) \cap T &= R \cap (S \cap T) \\
(R \cup S) \cup T &= R \cup (S \cup T)
\end{aligned}
$$

Estas reglas son validas tanto para **set**- como **bag-semantics**.

- ¿es p-join asociativo?
- ¿cuál es la importancia de estas reglas?

Distributividad

Las siguientes consultas son **equivalentes**:

$$R \cap_S (S \cup_S T) \quad = \quad (R \cap_S S) \cup_S (R \cap_S T)$$

¿qué ocurre para **bag-semantics**?

Selección: `AND` y `OR`

Las siguientes consultas son **equivalentes**:

$$\sigma_{p_1 \texttt{ AND } p_2}(R) = \sigma_{p_1}(\sigma_{p_2}(R)) = \sigma_{p_2}(\sigma_{p_1}(R))$$

$$\sigma_{p_1 \texttt{ OR } p_2}(R) = \sigma_{p_1}(R) \cup_S \sigma_{p_2}(R)$$

¿cuál es la utilidad de esta regla?

Selección: push-selection

Las siguientes consultas son **equivalentes**:

$$
\begin{aligned}
\sigma_p(R \times S) &= \sigma_p(R) \times S \\
\sigma_p(R \bowtie S) &= \sigma_p(R) \bowtie S \\
\sigma_p(R \bowtie_q S) &= \sigma_p(R) \bowtie_q S \\
\sigma_p(R \cap S) &= \sigma_p(R) \cap S
\end{aligned}
$$

si R tiene todos los atributos mencionados en p.

Selección: push-selection

Análogamente:

$$\begin{aligned}
\sigma_p(R \times S) &= R \times \sigma_p(S) \\
\sigma_p(R \bowtie S) &= R \bowtie \sigma_p(S) \\
\sigma_p(R \bowtie_q S) &= R \bowtie_q \sigma_p(S) \\
\sigma_p(R \cap S) &= R \cap \sigma_p(S)
\end{aligned}$$

si S tiene todos los atributos mencionados en p.

Selección: push-selection

Si R y S tiene todos los atributos mencionados en p, simultáneamente:

$$\begin{aligned}\sigma_p(R \bowtie S) &= \sigma_p(R) \bowtie \sigma_p(S)\\ \sigma_p(R \cap S) &= \sigma_p(R) \cap \sigma_p(S)\end{aligned}$$

Las siguientes consultas son siempre **equivalentes**:

$$\begin{aligned}\sigma_p(R \cup S) &= \sigma_p(R) \cup \sigma_p(S)\\ \sigma_p(R - S) &= \sigma_p(R) - \sigma_p(S) = \sigma_p(R) - S\end{aligned}$$

Ejemplo

Considere las relaciones $R(a, b)$ y $S(b, c)$, transformar:

$$\sigma_{(a=1 \texttt{ OR } a=3) \texttt{ AND } b<c}(R \bowtie S)$$

Selección: push-selection

- Una de las reglas mas importante de los optimizadores!
- ¿es siempre útil hacer push-selection?
- ¿puede ser útil hacer “pop-selection”?

Proyección: push-projection

"Haremos push-projection siempre y cuando solo eliminamos atributos que no son usados por los ancestros de ese nodo"

Proyección: push-projection

Las siguientes consultas son **equivalentes**:

$$
\begin{aligned}
\pi_L(R \bowtie S) &= \pi_L(\pi_M(R) \bowtie \pi_N(S)) \\
\pi_L(R \bowtie_p S) &= \pi_L(\pi_M(R) \bowtie_p \pi_N(S)) \\
\pi_L(R \times S) &= \pi_L(\pi_M(R) \times \pi_N(S)) \\
\pi_L(R \cup_B S) &= \pi_L(R) \cup_B \pi_L(S) \\
\pi_L(\sigma_p(R)) &= \pi_L(\sigma_p(\pi_M(R)))
\end{aligned}
$$

si M y N no "**interfieren**" con el join ni la proyección de L.

Ejemplo

Considere las relaciones $R(a, b, c)$ y $S(b, c, d)$, transformar:

$$\pi_{a,b}(R \bowtie S)$$

Joins y productos

Las siguientes consultas son **equivalentes**:

$$R \bowtie_p S = \sigma_p(R \times S)$$

$$R \bowtie S = \pi_L(\sigma_q(R \times S))$$

donde:

$$q := \bigwedge_{x \in \mathrm{attrib}(R) \cap \mathrm{attrib}(S)} R.x = S.x$$

$$L := \mathrm{attrib}(R) \cup_S \mathrm{attrib}(S).$$

¿cuál es la utilidad de esta regla?

Eliminación de duplicados

Las siguientes consultas son **equivalentes**:

$$
\begin{aligned}
\delta(R \times S) &= \delta(R) \times \delta(S) \\
\delta(R \bowtie S) &= \delta(R) \bowtie \delta(S) \\
\delta(R \bowtie_p S) &= \delta(R) \bowtie_p \delta(S) \\
\delta(\sigma_p(R)) &= \sigma_p(\delta(R))
\end{aligned}
$$

Siempre considerar que $\delta(R) = R$ si R NO tiene duplicados como:

- R tiene una llave primaria.
- R es el resultado de un group-by.
- R es el resultado de operadores con set-semantics.

GroupBy

- Reglas dependen mucho de las funciones de agregación.
- Algunas reglas:

$$\begin{aligned} \delta(\gamma_L(R)) &= \gamma_L(R) \\ \gamma_L(\delta(R)) &= \gamma_L(R) \quad (*) \end{aligned}$$

$(*)$ si L considera funciones de agregación como `MAX` o `MIN`.

Outline

¿qué reglas usar?

No existe una regla única!

Uso de heurísticas:

- hacer **push** de las **selecciones** lo mas abajo posible.
- hacer **push** de las **proyecciones** lo mas abajo posible.
- proyectar y eliminar atributos que no se usarán.
- convertir los productos en **equi-joins**.
- elegir el **mejor orden*** de joins, uniones o intersecciones.
- remover eliminación de duplicados.

¿qué reglas usar?

Ejemplo

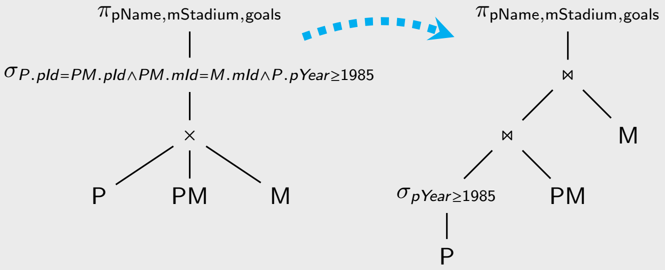

¿cómo decidir cuales planes lógicos son **prometedores**?

En base a (posibles criterios):

- tamaño de las relaciones intermedias.
- uso de índices.
- posibles sorting de los resultados.