

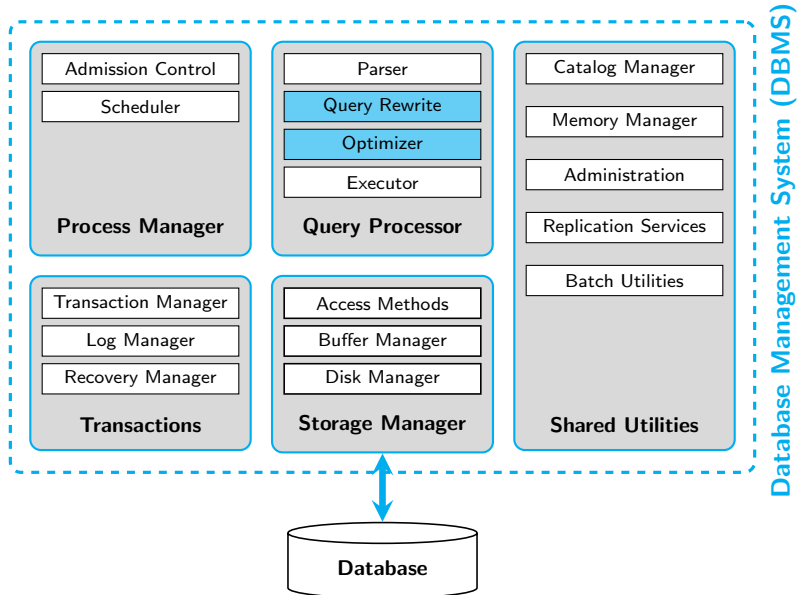
Optimización de Joins

Clase 16

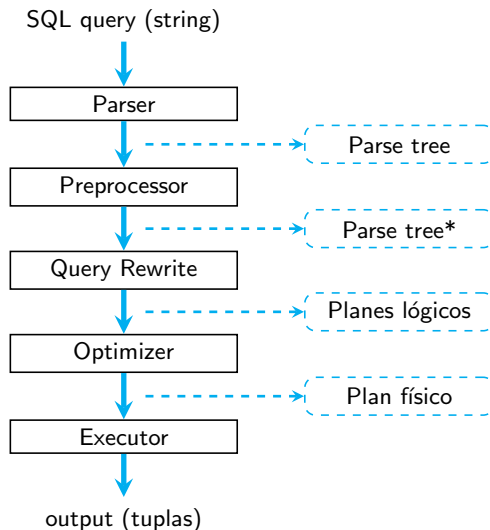
IIC 3413

Prof. Cristian Riveros

Optimización de consultas




Zoom al optimizador de consultas



Desde plan lógico a plan físico

Dado nuestro plan lógico:



¿cómo construir nuestro plan físico?

Encontrar el “mejor” plan físico

El **santo grial** de los DBMS!!!

Debemos escoger:


1. los operadores físicos para cada operador lógico.
2. el **orden** de joins/uniones/intersecciones.
3. que resultados **materializar**.

¿qué tan importante es un buen plan físico?

Suponga la siguiente consulta:

```
SELECT  *  
FROM    Players AS P, Matches AS M, Players_Matches AS PM  
WHERE   P.pld = PM.pld AND PM.mld = M.mld AND  
        P.name = 'Alexi' AND M.year = 2001
```

con el siguiente plan lógico:



¿cuál es el mejor plan físico?

Como escoger un plan físico

Primera posibilidad, la estrategia **exhaustiva**:

1. Enumerar todos los posibles planes físicos.
 - Para cada plan lógico, probar **todos** los operadores físicos.
2. Estimar el costo de cada plan físico.
3. Elegir el mejor plan físico y ejecutarlo.

Para enumerar planes, dos posibles estrategias:

- Top-down.
- Bottom-up.

¿es factible esta estrategia?

Alternativas a la estrategia exhaustiva

- Branch-and-bound.
- Hill climbing.
- Programación dinámica.
- Heurísticas.

Posibles heurísticas a considerar

- usar **index-scan** cuando hay índices.
- usar **index-join** cuando existe un índice sobre los atributos.
- preferir **sort-join** sobre hash-join cuando las relaciones están ordenadas.
- empezar el join/intersección/unión sobre las relaciones más pequeña.

El secreto mejor guardado de todo motor DBMS!

Encontrar el “mejor” plan físico




El **santo grial** de los DBMS!!!

Debemos escoger:

1. los operadores físicos para cada operador lógico. ✓
2. el **orden** de joins/uniones/intersecciones.
3. que resultados **materializar**.

Orden de operadores conmutativos y asociativos


Dado un plan de lógico con nodos de la forma:



¿qué **orden** de los operadores usamos en el plan físico?

Orden de joins


Para $R \bowtie S \bowtie T$, tenemos todos estos **planes** posibles:



¿cuál de todos escogemos?

¿cuántos planes de joins podemos escoger?

Para n -joins de la forma $R_1 \bowtie R_2 \bowtie \cdots \bowtie R_{n+1}$:



El número de posibles árboles de join para n -joins:

$$C_n = \sum_{k=0}^{n-1} C_k \cdot C_{n-k-1}$$

(conocidos como "Catalan numbers")

¿cuántos planes de joins podemos escoger?

Resolviendo esta ecuación recursiva:

$$C_n = \frac{(2n)!}{(n+1)!n!}$$

Multiplicando por todas las permutaciones $n!$ de las n relaciones:

$$\text{\#-planes de joins} = \frac{(2n)!}{(n+1)!}$$

Una cantidad exponencial de posibles planes!

¿y ahora quién podrá defendernos?

Tres opciones para enumerar planes de joins:

1. Considerarlos todos.
2. Considerar un subconjunto de los planes.
3. Usar una heurística.

1. Considerar todos los planes

Clave: usar **programación dinámica!**

Para un multi-join $R_1 \bowtie R_2 \bowtie \dots \bowtie R_n$:

■ **Caso base:** Para cada par $\{R_i, R_j\}$:

- Estimar el join con menor costo entre $R_i \bowtie R_j$ y $R_j \bowtie R_i$.
- Almacenar el mejor plan.

■ **Inducción (i):** Para cada subconjunto $\mathcal{R} \subseteq \{R_1, \dots, R_n\}$ con $|\mathcal{R}| = i$.

- Para cada división de $\mathcal{R} = \mathcal{R}_1 \uplus \mathcal{R}_2$.
- Estimar el join con menor costo entre:

$$(\bowtie_{R \in \mathcal{R}_1} R) \bowtie (\bowtie_{R \in \mathcal{R}_2} R) \quad \text{o} \quad (\bowtie_{R \in \mathcal{R}_2} R) \bowtie (\bowtie_{R \in \mathcal{R}_1} R)$$

- Almacenar el mejor plan de todas las particiones.

Enumeración basado en programación dinámica

- Encuentra el plan de joins con mejor costo (estimado).
- No es necesario enumerar todos los planes (¿cierto?).
- La cantidad de planes para joins de N -relaciones es mucho menor:

$$\sum_{k=1}^n \binom{n}{k} \cdot (2^k - 2) \leq 3^n \ll \frac{(2n)!}{(n+1)!}$$


¿Y ahora quién podrá defendernos?

Tres opciones para enumerar planes de joins:


1. Considerarlos todos. ✓
2. Considerar un subconjunto de los planes.
3. Usar una heurística.

2. Considerar un subconjunto de los planes


Distintos tipos de planes:



Left-deep plan



Bushy plan



Right-deep plan

¿qué ventaja tiene cada plan?

Subconjunto de planes prometedores

Considerar solo **left-deep** plans.

Ventajas:

- Un subconjunto menor de planes a considerar (¿cuantos?).
- Buena interacción con los operadores físicos de join.

Podemos considerar programación dinámica sobre este subconjunto!!

Optimizador de **Selinger**

Optimizador de Selinger

Clave (de nuevo): usar **programación dinámica**!

Para un multi-join $R_1 \bowtie R_2 \bowtie \dots \bowtie R_n$:

- **Caso base:** Para cada par $\{R_i, R_j\}$:
 - Estimar el join con menor costo entre $R_i \bowtie R_j$ y $R_j \bowtie R_i$.
 - Almacenar el mejor plan.
- **Inducción (i):** Para cada subconjunto $\mathcal{R} \subseteq \{R_1, \dots, R_n\}$ con $|\mathcal{R}| = i$.
 - Para cada $R \in \mathcal{R}$.
 - Estimar el join:

$$\left(\bowtie_{R' \in \mathcal{R} - \{R\}} R' \right) \bowtie R$$

- Almacenar el mejor plan de todos los R .

Ejemplo del optimizador de Selinger

Ejemplo

Calcular el tamaño/costo del natural join:

$$R(a, b) \bowtie S(b, c) \bowtie T(c, d) \bowtie U(d, a)$$

suponiendo que cada relación tiene 1000 tuplas y:

	$R(a, b)$	$S(b, c)$	$T(c, d)$	$U(d, a)$
$\text{distinct}_a(\cdot)$	100			50
$\text{distinct}_b(\cdot)$	200	100		
$\text{distinct}_c(\cdot)$		500	20	
$\text{distinct}_d(\cdot)$			50	1000

¿Y ahora quién podrá defendernos?

Tres opciones para enumerar planes de joins:

1. Considerarlos todos. ✓
2. Considerar un subconjunto de los planes. ✓
3. Usar una heurística.

3. Usar una heurística

Heurística **greedy** para: $R_1 \bowtie R_2 \bowtie \dots \bowtie R_n$

- Mantener un conjunto de planes \mathcal{P} .
- Iniciar el conjunto de planes \mathcal{P} con todas las relaciones:

$$\mathcal{P} = \{R_1, \dots, R_n\}$$

- En cada iteración, escoger dos planes $P_1, P_2 \in \mathcal{P}$ tal que:

$$\text{cost}(P_1 \bowtie P_2) = \min_{P, P' \in \mathcal{P}} \text{cost}(P \bowtie P')$$

y reemplazar $\mathcal{P} := (\mathcal{P} - \{P_1, P_2\}) \cup \{P_1 \bowtie P_2\}$.

¿cuál es el tiempo de esta heurística?

Otras heurísticas

- Algoritmos **aleatorios**.
- Algoritmos **genéticos**.

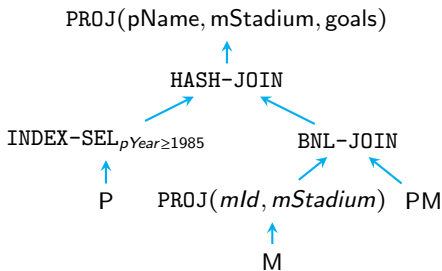
Encontrar el “mejor” plan físico

El **santo grial** de los DBMS!!!

Debemos escoger:

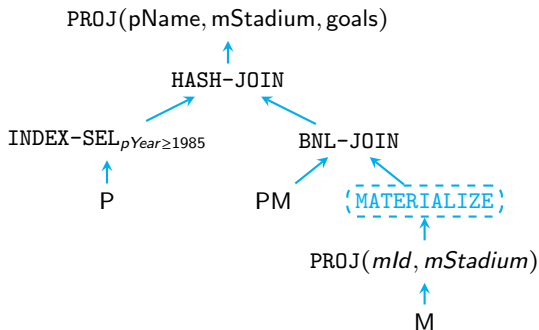
1. los operadores físicos para cada operador lógico. ✓
2. el **orden** de joins/uniones/intersecciones. ✓
3. que resultados **materializar**.

Pipeline



- Ejecución en serie del plan físico.
- Cada operador genera una tupla a la vez.
- Cada operador no almacena sus resultados intermedios y los retorna a su operador padre.

Materialización



- Almacena el resultado de la subconsulta en disco.
- Solo necesario si la subconsulta es requerida reiteradas veces.

Pipeline vs Materialización

Siempre se prefiere pipeline sobre materialización

Usar materialización si:

- Subconsulta es llamada reiteradas veces.
- Costo de almacenamiento es menor a recalcular la consulta.

Finalmente, ejecutamos nuestro plan físico de consultas...

