


# Complejidad de consultas

Clase 17

IIC 3413

Prof. Cristian Riveros

# Complejidad de consultas relacionales



# Complejidad de consultas relacionales

- ¿es posible mejorar más nuestro **optimizador**?
- ¿existe una estrategia **mejor** para evaluar consultas?
- ¿cuáles son las consultas más **difíciles**?

# Outline

Evaluación de consultas

Optimización de consultas

Consultas conjuntivas

# Outline

Evaluación de consultas

Optimización de consultas

Consultas conjuntivas

# ¿qué tan complejo es evaluar una consulta SQL?

Problema de **enumeración**:

PROBLEMA: Evaluación de consultas en SQL (SQL-ENUM).

INPUT: una consulta  $Q$  en SQL,  
una BD relacional  $\mathcal{D}$ .


OUTPUT:  $Q(\mathcal{D})$ .

Queremos un **algoritmo de enumeración** que sea polinomial en  $Q$  y  $\mathcal{D}$ :

- tiempo polinomial en  $Q$  y  $\mathcal{D}$  para entregar la **primera tupla** de  $Q(\mathcal{D})$ , y
- tiempo polinomial en  $Q$  y  $\mathcal{D}$  entre cada **siguiente tupla** de  $Q(\mathcal{D})$ .

¿cómo medimos la complejidad de SQL-ENUM?

# Micro-curso de complejidad computacional



- **PTIME:** problemas que pueden ser resueltos en **tiempo polinomial** en el tamaño del input.
- **NP:** problemas cuya solución puede ser **verificada** en **tiempo polinomial** en el tamaño del input/solución.
- **PSPACE:** problemas que pueden ser resueltos en **espacio polinomial** en el tamaño del input.
- **EXPTIME:** problemas que pueden ser resueltos en **tiempo exponencial** en el tamaño del input.

# Micro-curso de complejidad computacional


## Definición

- Un problema  $P$  es **hard** para una clase de complejidad  $\mathcal{C}$  si todos los problemas  $P' \in \mathcal{P}$  se pueden reducir (en tiempo polinomial) a  $P$ .
- Un problema  $P$  es **completo** para una clase de complejidad  $\mathcal{C}$  si:
  1.  $P \in \mathcal{C}$ .
  2.  $P$  es hard para  $\mathcal{C}$ .



# Micro-curso de complejidad computacional

Problemas completos para cada clase:



- **PTIME:** programación lineal, horn-SAT, circuit-eval.
- **NP:** SAT, problemas en grafo.
- **PSPACE:** QBF-SAT, juegos/puzzles.
- **EXPTIME:** ajedrez.

# ¿qué tan complejo es evaluar una consulta SQL?

Problema de **enumeración**:

PROBLEMA: Evaluación de consultas en SQL (SQL-ENUM).

INPUT: una consulta  $Q$  en SQL,  
una BD relacional  $\mathcal{D}$ .

OUTPUT:  $Q(\mathcal{D})$ .

Necesitamos un **problema de decisión** asociado a SQL-ENUM!

# Problema de decisión asociado a SQL-ENUM

PROBLEMA: Resultado no-vacío de consultas SQL (SQL-EMPTYNESS).

INPUT: una consulta  $Q$  en SQL,  
una BD relacional  $\mathcal{D}$

OUTPUT: TRUE ssi  $Q(\mathcal{D}) \neq \emptyset$ .

1. Si SQL-EMPTYNESS no está en PTIME (ej. es NP-HARD),  
¿implica que SQL-ENUM NO se puede enumerar en tiempo polinomial?
2. Si SQL-EMPTYNESS está en PTIME,  
¿implica que SQL-ENUM se puede enumerar en tiempo polinomial?

SQL-EMPTYNESS **solo nos puede dar evidencia** si el problema es difícil

# ¿qué tan complejo es evaluar una consulta SQL?

## Teorema

El problema SQL-EMPTYNESS es PSPACE-completo.

A menos que  $P = PSPACE$ , **no existe** un algoritmo de enumeración eficiente (en tiempo polinomial) para SQL-ENUM

¿cuáles son las consultas SQL **difíciles** de evaluar?

- Consultas de la forma: NOT EXIST... EXIST... NOT EXIST...
- Consultas con negación anidadas.

# Outline

Evaluación de consultas

**Optimización de consultas**

Consultas conjuntivas

# Problemas asociados a optimización de consultas en SQL

Para la optimización de consultas en SQL,  
nos interesan **algoritmos eficientes** para los siguientes problemas:

PROBLEMA: Satisfabilidad de SQL (SQL-SAT).

INPUT: una consulta  $Q$  en SQL,

OUTPUT: TRUE ssi existe  $\mathcal{D}$  tal que  $Q(\mathcal{D}) \neq \emptyset$ .

PROBLEMA: Igualdad de consultas SQL (SQL-EQUIVALENCE).

INPUT: consultas  $Q_1$  y  $Q_2$  en SQL,

OUTPUT: TRUE ssi para todo  $\mathcal{D}$  se cumple  $Q_1(\mathcal{D}) = Q_2(\mathcal{D})$ .

¿para que nos serviría resolver estos problemas?

# Es imposible tener un optimizador perfecto para SQL

## Teorema

Para SQL, los siguientes problemas son **indecidibles**:

- SQL-EQUIVALENCE
- SQL-SAT

**indecidable** = no existe algoritmo alguno que solucione el problema

¿es posible hacer “algo” para mejorar la evaluación/optimización en SQL?

# Outline

Evaluación de consultas

Optimización de consultas

**Consultas conjuntas**



# Fragmento más sencillo: consultas conjuntivas

## Definición

Una **consulta conjuntiva** (CQ) es una consulta en AR que solo contiene:

- proyección ( $\pi$ )
- selección sencilla ( $\sigma_{A=B} \circ \sigma_{A=v}$ )
- Equality joins ( $\bowtie_{A=B}$ )
- Renaming ( $\rho_{A \rightarrow B}$ )

## Ejemplo

```
SELECT  P.name, M.goals
FROM    Players AS P, Matches AS M, Players_Matches AS PM
WHERE   P.pld = PM.pld AND PM.mld = M.mld AND
        P.name = 'Alexi' AND M.year = 2001
```

En otras palabras, una consulta SELECT-FROM-WHERE.

# Fragmento más sencillo: consultas conjuntivas

## Definición

Una **consulta conjuntiva** (CQ) es una consulta en AR que solo contiene:

- proyección ( $\pi$ )
- selección sencilla ( $\sigma_{A=B} \circ \sigma_{A=v}$ )
- Equality joins ( $\bowtie_{A=B}$ )
- Renaming ( $\rho_{A \rightarrow B}$ )

## Sin pérdida de generalidad

Desde ahora en adelante consideraremos consultas conjuntivas solo con:

- proyección  $\pi$ .
- selección  $\sigma_{A=v}$ .
- natural joins  $\bowtie$ .

$\sigma_{A=B}$ ,  $\bowtie_{A=B}$  y  $\rho_{A \rightarrow B}$  no cambian la complejidad del problema.

## Fragmento más sencillo: consultas conjuntivas

### Proposición

Para toda consulta conjuntiva  $Q$ , existe una consulta  $Q'$  tal que  $Q(\mathcal{D}) = Q'(\mathcal{D})$  para toda BD  $\mathcal{D}$  y  $Q'$  es de la forma:

$$\pi_I(\sigma_{c_1}(R_1) \bowtie \dots \bowtie \sigma_{c_n}(R_n))$$

con cada  $c_i$  una conjunción filtros  $A = v$ .

Demostración: use las reglas de reescritura.

# Representación simplificada de consultas conjuntivas

Sea **V** un conjunto de variables y **C** un conjunto de constantes.

## Simplificación

Desde ahora una consulta conjuntiva la representaremos como:

$$ans(\bar{y}) := R_1(\bar{x}_1), R_2(\bar{x}_2), \dots, R_n(\bar{x}_n)$$

1.  $\bar{x}_1, \dots, \bar{x}_n$  son variables en **V** o constantes en **C**,
2.  $\bar{y}$  es un subconjunto de variables en  $\bar{x}_1, \dots, \bar{x}_n$ .

## Ejemplo

$$ans(x, z) := P(x, 'Alexi'), PM(x, y), M(y, 2001, z)$$

- $x, y, z$  son variables.
- 'Alexi' y 2001 son constantes.

# Representación simplificada de consultas conjuntivas

Sea **V** un conjunto de variables y **C** un conjunto de constantes.

## Simplificación

Desde ahora una consulta conjuntiva la representaremos como:

$$ans(\bar{y}) := R_1(\bar{x}_1), R_2(\bar{x}_2), \dots, R_n(\bar{x}_n)$$

1.  $\bar{x}_1, \dots, \bar{x}_n$  son variables en **V** o constantes en **C**,
2.  $\bar{y}$  es un subconjunto de variables en  $\bar{x}_1, \dots, \bar{x}_n$ .

## Notación

- $R_1(\bar{x}_1), \dots, R_n(\bar{x}_n)$  es el **cuerpo** de  $Q$  y  $ans(\bar{y})$  es la **cabeza** de  $Q$ .
- cada  $R_i(\bar{x}_i)$  es un **átomo** de  $Q$ .
- si  $\bar{y}$  es **vacía**, entonces hablamos de una **consulta booleana**.

# Homomorfismo de consultas conjuntivas

Sea  $\mathbf{V}$  un conjunto de variables y  $\mathbf{C}$  un conjunto de constantes.

A partir del cuerpo de una consulta conjuntiva  $Q$ :

$$R_1(\bar{x}_1), R_2(\bar{x}_2), \dots, R_n(\bar{x}_n)$$

se define una base de datos  $\mathcal{D}_Q$  sobre el dominio  $\mathbf{V} \cup \mathbf{C}$  donde:

$$(d_1, \dots, d_k) \in \mathcal{D}_Q(R) \text{ ssi } R(d_1, \dots, d_k) \text{ es un átomo de } Q.$$

## Ejemplo

$$ans(x, z) := P(x, 'Alexi'), PM(x, y), M(y, 2001, z)$$

- $\mathcal{D}_Q(P) = \{(x, 'Alexi')\}$
- $\mathcal{D}_Q(PM) = \{(x, y)\}$
- $\mathcal{D}_Q(M) = \{(y, 2001, z)\}$

# Homomorfismo de consultas conjuntivas

Sea  $\mathbf{V}$  un conjunto de variables y  $\mathbf{C}$  un conjunto de constantes.

A partir del cuerpo de una consulta conjuntiva  $Q$ :

$$R_1(\bar{x}_1), R_2(\bar{x}_2), \dots, R_n(\bar{x}_n)$$

se define una base de datos  $\mathcal{D}_Q$  sobre el dominio  $\mathbf{V} \cup \mathbf{C}$  donde:

$$(d_1, \dots, d_k) \in \mathcal{D}_Q(R) \text{ ssi } R(d_1, \dots, d_k) \text{ es un átomo de } Q.$$

## Definición

Un **homomorfismo** de  $Q$  a  $\mathcal{D}$  es una función  $h: (\mathbf{V} \cup \mathbf{C}) \rightarrow \mathbf{C}$  tal que:

- $h(c) = c$  para toda  $c \in \mathbf{C}$  y
- $(d_1, \dots, d_k) \in \mathcal{D}_Q(R)$ , entonces  $(h(d_1), \dots, h(d_k)) \in \mathcal{D}(R)$  para todo nombre de relación  $R$ .

## Homomorfismo de consultas conjuntivas

### Definición

Un **homomorfismo** de  $\mathcal{Q}$  a  $\mathcal{D}$  es una función  $h: (\mathbf{V} \cup \mathbf{C}) \rightarrow \mathbf{C}$  tal que:

- $h(c) = c$  para toda  $c \in \mathbf{C}$  y
- $(d_1, \dots, d_k) \in \mathcal{D}_Q(R)$ , entonces  $(h(d_1), \dots, h(d_k)) \in \mathcal{D}(R)$  para todo número de relación  $R$ .

¿cuál es un homomorfismo de  $Q$  a  $\mathcal{D}$ ?

$$Q: \quad \text{anx}(x, z) := P(x, \text{'Alexi'}, y), M(x, z, \text{'3'})$$

$\mathcal{D}$ :	Players (P):			Matches (M):		
	Id	Name	Year	Id	Stadium	Goals
	1	Alexi	1987	1	Nacional	3
	2	Gary	1990	1	Monumental	3
	3	Arturo	1985	2	San Carlos	4



# Homomorfismo de consultas conjuntivas

## Definición

Un **homomorfismo** de  $Q$  a  $\mathcal{D}$  es una función  $h : (\mathbf{V} \cup \mathbf{C}) \rightarrow \mathbf{C}$  tal que:

- $h(c) = c$  para toda  $c \in \mathbf{C}$  y
- $(d_1, \dots, d_k) \in \mathcal{D}_Q(R)$ , entonces  $(h(d_1), \dots, h(d_k)) \in \mathcal{D}(R)$  para todo nombre de relación  $R$ .

## Proposición

Para toda base de datos  $\mathcal{D}$  y toda consulta conjuntiva  $Q$  de la forma:

$$ans(y_1, \dots, y_k) := R_1(\bar{x}_1), R_2(\bar{x}_2), \dots, R_n(\bar{x}_n)$$

se tiene que  $t \in Q(\mathcal{D})$  si, y solo si, existe un homomorfismo  $h$  de  $Q$  a  $\mathcal{D}$  con

$$t = (h(y_1), \dots, h(y_k)).$$

Demostración: ejercicio.

# ¿qué tan complejo es evaluar una consulta conjuntiva?

Problema de **decisión**:

PROBLEMA: Resultado no-vacío de consultas conjuntivas (CQ-EMPTYNESS).

INPUT: una consulta conjuntiva  $Q$ ,  
una BD relacional  $\mathcal{D}$

OUTPUT: TRUE ssi  $Q(\mathcal{D}) \neq \emptyset$ .

## Teorema

El problema CQ-EMPTYNESS es NP-completo.

# ¿estamos modelando el problema correctamente?

PROBLEMA: Resultado no-vacío de consultas conjuntivas (CQ-EMPTYNESS).

INPUT: una consulta conjuntiva  $Q$ ,  
una BD relacional  $\mathcal{D}$

OUTPUT: TRUE ssi  $Q(\mathcal{D}) \neq \emptyset$ .

En la práctica tenemos que:

$$|Q| \ll |\mathcal{D}|$$

Consultas son muchísimo más pequeñas que los datos.

# Complejidad en término de los datos

- **Combined**-complexity: consulta y datos son parte del input.
- **Data**-complexity: solo los datos son parte del input (consulta esta fija).

PROBLEMA: Resultado no-vacío de consultas conjuntivas  $Q$  ( $\text{CQ-EVAL}_Q$ ).

INPUT: una BD relacional  $\mathcal{D}$

OUTPUT:  $t \in Q(\mathcal{D})$ .

# Complejidad en término de los datos

## Teorema

El problema  $\text{CONJSQL-EVAL}_Q$  esta en PTIME para todo consulta  $Q \in \text{SQL}$ .

¿es posible hacer una análisis mas fino?

# Equivalencia y satisfiabilidad de consultas conjuntivas

## Definición

Un **homomorfismo** de  $Q_1$  a  $Q_2$  es una función  $h : (\mathbf{V} \cup \mathbf{C}) \rightarrow (\mathbf{V} \cup \mathbf{C})$ :

- $h(c) = c$  para toda  $c \in \mathbf{C}$ ,
- si  $(d_1, \dots, d_k) \in \mathcal{D}_{Q_1}(R)$ , entonces  $(h(d_1), \dots, h(d_k)) \in \mathcal{D}_{Q_2}(R)$  y
- si  $ans(y_1, \dots, y_k)$  es el cuerpo de  $Q_1$ ,  
entonces  $ans(h(y_1), \dots, h(y_k))$  es el cuerpo de  $Q_2$ .

## Proposición

Para todo par de consultas conjuntivas  $Q_1$  y  $Q_2$  se tiene que:

1.  $Q_1(\mathcal{D}) \subseteq Q_2(\mathcal{D})$  para toda  $\mathcal{D}$  si, y solo si,
2. existe un homomorfismo de  $Q_2$  a  $Q_1$ .

# Equivalencia y satisfiabilidad de consultas conjuntivas

PROBLEMA: Satisfiabilidad de consultas conjuntivas. (CQ-SAT).

INPUT: una consulta conjuntiva  $Q$ ,

OUTPUT: TRUE ssi existe  $\mathcal{D}$  tal que  $Q(\mathcal{D}) \neq \emptyset$ .

PROBLEMA: Igualdad de consultas conjuntivas (CQ-EQUIVALENCE).

INPUT: consultas conjuntivas  $Q_1$  y  $Q_2$ ,

OUTPUT: TRUE ssi para todo  $\mathcal{D}$  se cumple  $Q_1(\mathcal{D}) = Q_2(\mathcal{D})$ .

## Teorema

- CQ-SAT es un problema trivial (siempre es satisfacible).
- CQ-EQUIVALENCE es NP-COMPLETO.